从 153 列到 110 列

跨年对齐：人工映射与本地小模型的两条路

2019–2024 六份原始表

42 个跨年共有列

203,643 行 → 185,632 行

→ 153（人工）

110（本地 4B 模型）

汇报人：曾子睿

2026 年 11 月

原始数据版权归 JetBrains / PSF 所有，此处只涉及对齐口径与脚本。

一页看清成果

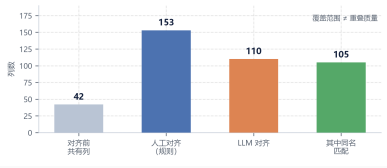
人工路线交付完整总表；LLM 路线少 43 列，但两边都有的 105 列几乎逐格一致。

153
跨年共有列（原 42）

382
列名重命名

109,745
取值统一记录

185,632
总表行数



LLM：110 列·305 条重命名
31 个同义簇·取值 5,217 条（单元格）
105 列重叠，非空率差 ≥1pp：**0 条**
同主题最大差 **0.1pp**（12 条对比）

总行数 185,586，比人工少 46

来源：`aligned/alignment_report.md`；`llm/reports/alignment_report.md`；`llm/reports/parity_report.md`

手搓对齐：先归组，再改名，最后动取值

顺序不能反。先改列名再归组，前面的改动会被后一步覆盖。

01 文本归一 → 02 组路径重映射 → 03 列名统一 → 04 取值文案统一 → 05 取交集 153 列

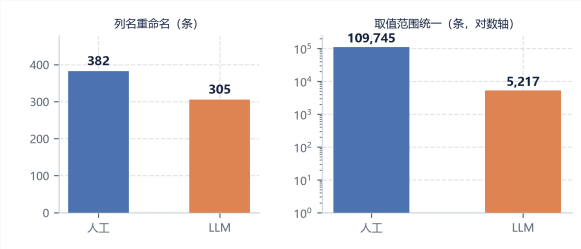
改之前	改之后
`isolate.environments.Docker`	`environments.isolate.Docker`
`what_other_language_s...[Other]`	`other.lang.Other - Write In`
`OS-provided Python (via apt-get...)`	`OS-provided Python`

撞名先回退确定性归一，再撞才加 `__dupN`；取值只合并同一选项的不同写法。

来源：`aligned/alignment_report.md`；`align_survey.py`

手搓的代价：2019 一年改了 201 个列名

成本集中在第一次遇到新题型；后面五年加起来 181 条，维护靠同义词表逐年补。



分年重命名：2019 **201** ·31 ·48 ·43 ·25 ·34；2019 列名是整句问句，等于没有命名规范。

来源：`aligned/alignment_report.md` 分年统计；`llm/reports/alignment_report.md` 校验提示

小模型：只动嘴，不动手

模型输出可校验的决策 JSON；执行、护栏、缓存都在 Python 里。



304 个决策文件：clean 149、align 130、stats 14，其余 11 个。

首次全量约 30 分钟；命中缓存 2.7 分钟。

组路径 20 处改道、选项同义簇 31 个；
逐对判定 162 对（接受 34 对），取值统一 5,217 条——

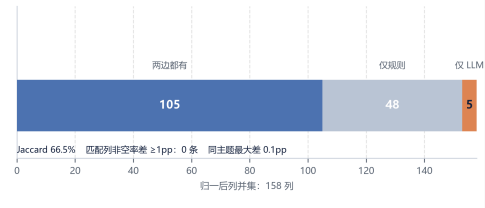
4B 不生成写法，只答“是不是同一个”。

护栏：Yes/No 禁改道版本路径·题型冲突拒合·选项指纹 Jaccard ≥0.2 ·结构不得重复拼接·簇 ≤4 且 ≤50%。

来源：`llm/README.md`；`llm/decisions/` 计数；`llm/reports/alignment_report.md`

对账：覆盖差 43 列，重叠部分几乎一样

名字对了、语义错了，比没对齐更难发现。



并集 158 = 105 匹配 + 48 仅人工 + 5 仅 LLM；Jaccard 66.5%。
105 个匹配列非空率差 ≥1pp：**0 条**；同主题最大差 0.1pp。

2023/2024 人工映射未进提示词，105 是留出测试成绩。

改造前的反例：`is.python.main` 被映射成 `ide.python_version`。
路径合法，但语义是“是否以 Python 为主”，不是版本；2019 年五个来源列并成一组，四个版本列变 `__dup`。

现在取值指纹护栏直接拒掉。

来源：`llm/reports/parity_report.md`；`llm/reports/alignment_report.md`

结论：交付走人工，模型做候选与核对

两条路可以并存；模型写得最顺的差异解释，反而最不能直接信。

能交给模型

- 逐对判同题、判同义：只答 a/b，聚簇交给代码。
- 新一年的组路径候选，人工只审 diff。
- 对账差异草稿，数字由脚本回填。

必须留给人

- 命名终审：候选路径与选项写法由人工词表定。
- 删行删列：宁可少删，不能误删。
- 数字与结论：叙述可润色，数值以 CSV 为准。

下一步：给跨年改名题补名称证据（`develop.for.cloud`、`orm`、`unittesting` 仍判 `keep`）；被拒映射进人工确认队列；统计与图表跟对齐产物自动重跑。

谢谢大家！