从 153 列到 40 列

跨年对齐：人工映射与本地小模型的两条路

2019–2024 六份原始表

42 个跨年共有列

203,643 行 → 185,632 行

→ 153（人工）

40（本地 4B 模型）

汇报人：曾子睿

2026 年 11 月

原始数据版权归 JetBrains / PSF 所有，此处只涉及对齐口径与脚本。

一页看清成果

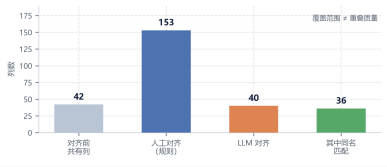
人工路线交付完整总表；LLM 路线列数少，但两边都有的 36 列几乎逐格一致。

153
跨年共有列（原 42）

382
列名重命名

109,745
取值统一记录

185,632
总表行数



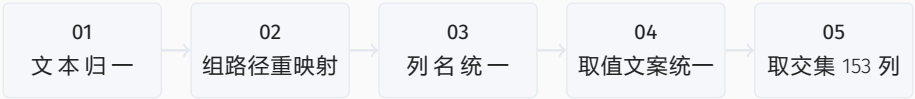
LLM：40 列·171 条重命名
9 个同义簇·取值 0 条
36 列重叠，非空率差 ≥1pp：**0 条**
同主题最大差 **0.1pp**（12 条对比）

总行数 185,586，比人工少 46

来源：`aligned/alignment_report.md`；`llm/reports/alignment_report.md`；`llm/reports/parity_report.md`

手搓对齐：先归组，再改名，最后动取值

顺序不能反。先改列名再归组，前面的改动会被后一步覆盖。



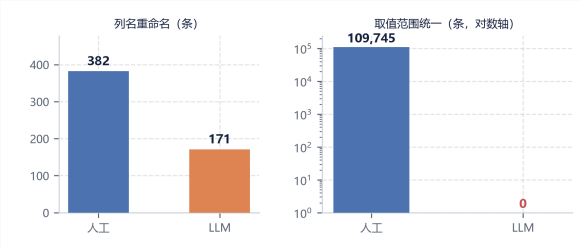
改之前	改之后
`isolate.environments.Docker`	`environments.isolate.Docker`
`what_other_language_s...[Other]`	`other.lang.Other - Write In`
`OS-provided Python (via apt-get...)`	`OS-provided Python`

撞名先回退确定性归一，再撞才加 `__dupN`；取值只合并同一选项的不同写法。

来源：`aligned/alignment_report.md`；`align_survey.py`

手搓的代价：2019 一年改了 201 个列名

成本集中在第一次遇到新题型；后面五年加起来 181 条，维护靠同义词表逐年补。



分年重命名：2019 **201** ·31 ·48 ·43 ·25 ·34；2019 列名是整句问句，等于没有命名规范。

来源：`aligned/alignment_report.md` 分年统计；`llm/reports/alignment_report.md` 校验提示

小模型：只动嘴，不动手

模型输出可校验的决策 JSON；执行、护栏、缓存都在 Python 里。



230 个决策文件：clean 149、align 58、stats 14，其余 9 个。

首次全量约 30 分钟；命中缓存 2.6 分钟。

组路径 21 处改道、选项同义簇 9 个；

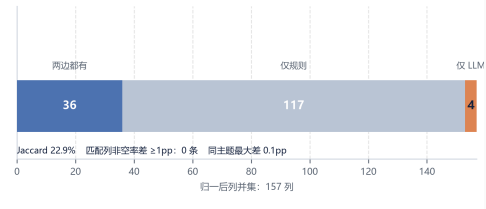
取值统一 0 条——4B 的归并建议几乎都是整列塌缩，被护栏全部拒绝。

护栏：路径必须合法·选项簇 ≤4 且 ≤50% ·整组塌缩一律拒·删行 ≤60% ·删列 ≤20%。

来源：`llm/README.md`；`llm/decisions/` 计数；`llm/reports/alignment_report.md`

对账：覆盖差 113 列，重叠部分几乎一样

名字对了、语义错了，比没对齐更难发现。



并集 157 = 36 匹配 + 117 仅人工 + 4 仅 LLM；Jaccard 22.9%。

36 个匹配列非空率差 ≥1pp：**0 条**；同主题最大差 0.1pp。

反例：`is.python.main` 被映射成 `ide.python_version`。路径合法，但语义是“是否以 Python 为主”，不是版本；2019 年五个来源列并成一组，四个版本列变 `__dup`。

来源：`llm/reports/parity_report.md`；`llm/reports/alignment_report.md`

结论：交付走人工，模型做候选与核对

两条路可以并存；模型写得最顺的差异解释，反而最不能直接信。

能交给模型

- 新一年的组路径候选，人工只审 diff。
- 对账时的第二双眼睛：先让它找差异，再回代码验。
- 把差异写成解释草稿，数字由脚本回填。

必须留给人

- 取值归并终审：4B 只会整列塌缩。
- 删行删列：宁可少删，不能误删。
- 数字与结论：叙述可润色，数值以 CSV 为准。

下一步：组路径映射加选项级证据（看到 Yes/No 就拒绝“版本”路径）；parity 从 36 列扩到 153 列的分主题抽样。

谢谢大家！