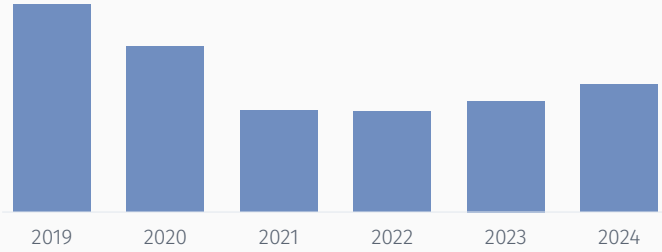
从原始 CSV 到干净数据表

PSF 开发者调查数据清洗的两周实践



清洗后各年行数（千），六年合计 185,632 行

汇报人：（待填）

2026 年 10 月

原始数据版权归 JetBrains / PSF 所有，此处只涉及清洗脚本与统计口径。

这两周交付了什么

把六份原始 CSV 洗成六份能直接读的表，脚本可以重跑。

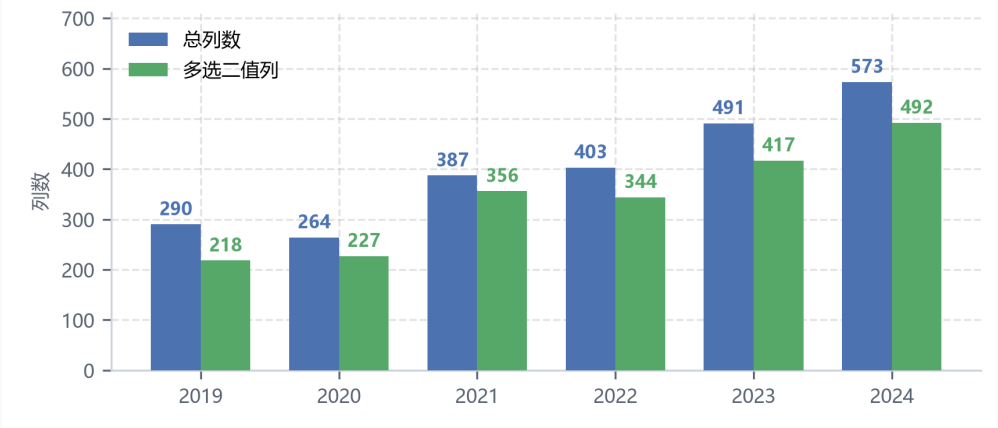
6	2,408	18,011	2,054
个年份，2019–2024	原始列（六年合计）	删除的行（8.8%）	二值化的多选列

行数从 203,643 变成 185,632。删掉的都是空行和重复行，没有按规则筛人。

来源：`cleaned/cleaning_report.md`

先看清数据长什么样

六年列数从 290 涨到 573，其中七成以上是选择题按选项拆出来的列。



表头有两套写法：2019 年是整句问句，2020 年以后是点分前缀。

两周的路径

不套模板，从数据本身的问题出发，一个问题一个问题往下问。

01

认数据

列数在涨吗？

行列多少，表头有几种，缺失到什么程度。

先看不写。

02

定口径

缺失怎么算？

没回答、写了 NA、答了 None 是三件事，定了再动手。

03

洗单元格

哪些行是废的？

空白、标点、全角半角，还有整行重复。

04

规范列名

说的是同一件事吗？

问句表头转点分，多选题拆成 0/1 列。

顺序是问题推出来的，不是抄来的。每问完一步就回数据里数一遍，数不对就说明上一步的口径错了。

数据：仓库根目录六份原始 CSV 与 `cleaned/` 下的清洗产物

第一课：没回答和答了 None 是两回事

pandas 默认会把 None 读成缺失，可这份数据里 None 是答案。

未回答

受访者跳过这题，格子里就是空的。不能当 0，也不能当「否」。

N/A 之类的写法

代码里收了 NA、n/a、nan 等六种写法，统一归成空字符串。

None 是答案

「一个都不用」是有效信息，必须原样留着。

```
pd.read_csv(path, encoding="utf-8-sig", keep_default_na=False)
```

25.5% 2019 年 is.python.main 的未回答比例。问卷跳答，不能补 0，也不能算作「否」。

来源：clean_survey.py（MISSING_TOKENS）；缺失率由 cleaned_2019.csv 实测。

六步洗下来

顺序不能乱，每一步只解决一类问题。

01 缺失归空 → 02 列名规范化 → 03 去空行空列 → 04 去重复行 → 05 多选二值化 → 06 数值转换

归空要在改列名之前

判重要按内容比，列名一变就对不上。

去重要在二值化之前

0/1 化会把原本不同的两行洗成一样。

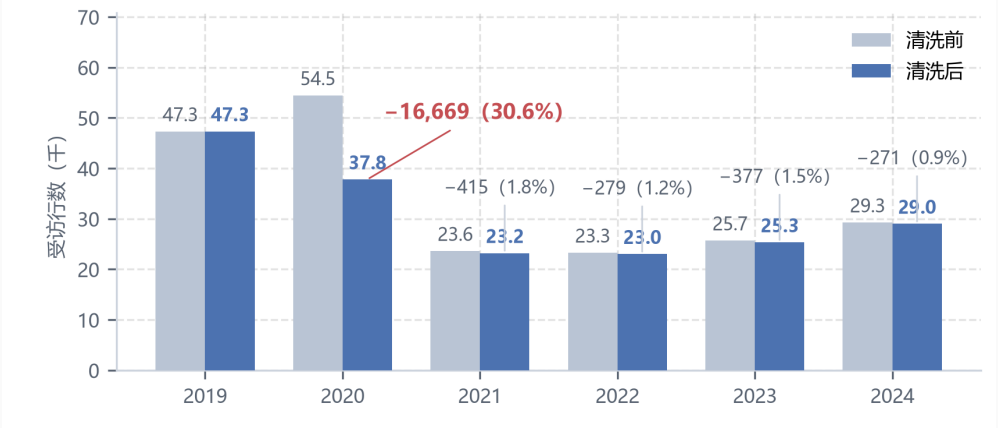
列只改不删

六年空列、重复列都是 0，问题靠重命名和取值统一解决。

来源：clean_survey.py、cleaned/cleaning_report.md

删掉的 18,011 行是怎么来的

九成集中在 2020 年，那里混着 12,554 个全空行和 4,115 个重复行。



其他年份只删重复回答：2021 年 415 行、2022 年 279 行、2023 年 377 行、2024 年 271 行。

列名规范化：问句表头怎么变成点分命名

2019 年的表头是整句问句，选项在冒号前面，得先拆开再套上统一的组前缀。

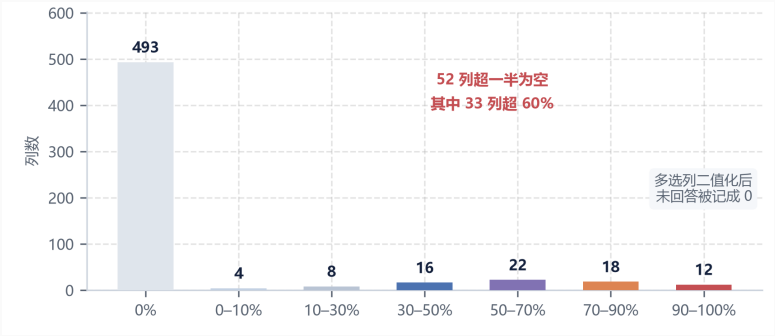
2019 原始表头	规范化之后
`Is Python the main language…`	`is.python.main`
`Bash / Shell:What other language…`	`other.lang.Bash / Shell`
`What do you use Python for?[Data analysis]`	`other.purposes.Data analysis`

2019 年一共改了 289 个列名。重名的两列在旧列名后加 `__dup` 后缀，不合并。

没解决的是组路径：环境隔离 2020 年挂在 `isolate.environments`，2023 年挂在 `environments.isolate`。这属于跨年对齐，还没做到。

来源：`clean_survey.py`（`rename_columns`）、`cleaned/cleaning_report.md`

多选题：2,054 列改成 0/1



2024 年 573 个列的缺失率分布：横轴是缺失率区间，纵轴是列数

代价在这里：二值化以后，0 既表示「没勾」，也表示「这题没答」。2024 年 573 列里有 493 列因此看不出缺失。

来源：clean_survey.py (binarize_multiselect)；缺失率由 cleaned_2024.csv 实测。

复盘：学会了什么，还没做什么

清洗这一段算是走通了，但整个流程只完成了三分之一。

已经做的

- 口径写在代码里：缺失标记、分母、二值化规则都能查到出处。
- 步骤之间有依赖，顺序定下来就不容易错。
- 每一步都留了数量，改完能立刻核对有没有洗坏。

还没做的

- 跨年对齐：列名和取值都还没统一，现在只能一年一年看。
- 统计与图表：只学了方法，没产出结论。
- 口径文档：目前散在脚本注释里，还没整理成一份说明。

下一步先把对齐补上，再谈跨年比较。

汇报到这里，欢迎提问。